

Python在财务管理中的应用

数据采集


1 案例背景

2 知识准备

3 任务要求

4 任务解析

随着互联网的迅速普及发展,它已经逐渐融入人们工作生活的方方面面。其中互联网是人与人、人与组织、组织与组织之间互相沟通、获取外界信息的重要途径。随着时间的推移,互联网的信息规模增长迅速,已经成为世界上最大的数据库,越来越多的个人和组织日益倚重互联网数据来学习和决策,典型的应用包括价格情报、同行业财务数据分析、市场调查、智能获客、背景调查、风险管理等等。快速的获取互联网信息是数据分析和挖掘的基础,通过python语言编写爬虫程序可以根据不同的应用场景获取对应的数据信息,为后续数据分析和决策提供支持



财务人员工作中需要通过互联网获取的数据有哪些，不同的数据的应用场景和解决的问题是什么？

1 案例背景

2 知识准备

3 任务要求

4 任务解析

网络爬虫是一种从网页上抓取数据信息并保存的自动化程序。如果我们把互联网比作一张大的蜘蛛网，数据便是存放于蜘蛛网的各个节点，而爬虫就是一只小蜘蛛（程序），沿着网络抓取自己的猎物（数据）。下面简要介绍一下爬虫的基本概念与流程：



1. 获取网页

网络爬虫第一步是通过一定的方式获取网页。所谓获取网页可以简单理解为在本地发起一个服务器请求，服务器则会返回给我们网页的源代码，其中通信的底层原理较为复杂，而Python给我们封装好了urllib库和requests库等，这些库可以让我们非常简单的发送各种形式的请求。

2. 提取信息

网页的源代码包含了非常多的信息，而想要进一步的获取我们的想要的信息则需要对源代码中的信息进行进一步的提取。此时我们可以选用python中的re库即通过正则匹配的形式去提取信息，也可以采用BeautifulSoup库（bs4）等解析源代码。

3. 保存数据

在提取到网页源代码中我们想要的信息之后则需要在python中将它们保存起来，可以使用通过内置函数open保存为文本数据等，也可以通过第三方库保存为其它形式的数据，例如可以通过pandas库保存为常见的xlsx数据，如果有图片等非结构化数据还可以通过pymongo库保存至非结构化数据库中。

4. 自动化程序

在经过前三步即ETL（Extract-Transform-Load）过程之后就可以将我们的爬虫代码有效地组织起来构成一个爬虫自动化程序，需要相同或相似数据的时候可以高效复用。

大量的爬虫在同一时间对网站进行访问，很容易导致网站服务器过载或崩溃，造成网站经营者的损失。开发者使用爬虫技术，如果请求频率过高，一旦造成目标服务器瘫痪或不能访问，这个就不是爬虫行为，而是黑客行为，必定要承担相应的责任。国家很早就发现了爬虫可能存在的问题，在2019年05月28日国家网信办发布的**《数据安全管理办法（征求意见稿）》**中，拟通过行政法规的形式，对爬虫的使用进行限制。其中就提到了数据收集的规则、数据的使用处理、数据安全监督管理等方面的内容。如果爬虫行为不当或者爬取内容不当，可能涉及到法律风险，因此在掌握爬虫技术的同时，要注意编写的爬虫程序不能损害网站的正常运行，**不能抓取企业和个人的隐私信息。**

Web网页可以分为HTML、CSS和JavaScript三个部分。如果把网页比作一个人的话，HTML相当于骨架，JavaScript相当于肌肉，CSS相当于皮肤，三者结合起来才能形成一个完善的网页。网络爬虫就是通过解析网页来进行数据爬取的，因此要对Web三件套有个整体认识，才能更好的进行数据采集的爬虫编写。

HTML：超文本标记语言（英语：HyperText Markup Language，简称：HTML）是一种用于创建网页的标准标记语言。您可以使用 HTML 来建立自己的Web站点，HTML 运行在浏览器上，由浏览器来解析，例如下面是一个简单的HTML页面的代码。

简单HTML页面代码

```
<!DOCTYPE html>
<html>
<head><meta charset="utf-8">
  <title>Html页面</title>
</head>
<body>
<h1>我的第一个标题</h1>
<p>我的第一个段落。</p>
<table border="1">
  <tr>
    <td>单元格1</td>
    <td>单元格2</td>
  </tr>
  <tr>
    <td>单元格3</td>
    <td>单元格4</td>
  </tr>
</table>
</body>
</html>
```


网页页面显示效果

file:///E:/04_课程和题库资源/07_python在财务管理中的应用/01_课程开发/Form.html

我的第一个标题

我的第一个段落。

单元格1	单元格2
单元格3	单元格4



能够看懂Html的代码，是抓取数据的时候很好的定位到要抓取的网页元素的关键，Html代码的入门，可参考html5的菜鸟教程。

教程链接：<https://www.runoob.com/html/html-tutorial.html>


JavaScript（简称“JS”）是一种具有函数优先的轻量级，解释型或即时编译型的编程语言。虽然它是作为开发Web页面的脚本语言而出名的，但是它也被用到了很多非浏览器环境中，JavaScript 基于原型编程、多范式的动态脚本语言，并且支持面向对象、命令式和声明式（如函数式编程）风格。例如在浏览器中打开百度页面，点击右键-查看网页源代码，即可发现JavaScript代码，负责网页的行为。




```
93 // 隐藏页面内容
94 var css='body {display: none!';
95     head=document.head||document.getElementsByTagName('head')[0],
96     style=document.createElement('style');
97
98     if(style.styleSheet){
99         style.styleSheet.cssText = css;
100     }else{
101         style.appendChild(document.createTextNode(css));
102     }
103
104     head.appendChild(style);
105     if(hashMatch[2]){
106         var encodeQuery=hashMatch[2].replace(/&/g, '%26').replace(/\\+/g, '%2B');
107         hashMatch[1]=hashMatch[1].split('wd=')[0]+'wd='+encodeQuery;
108     }
109
110     location.href="//"+location.host+"/"+s?"+hashMatch[1];
111 }
112 }}();
113
114 </script><script data-compress=strip>
115     function h(obj){
116         obj.style.behavior='url(#default#homepage)';
117         var a = obj.setHomePage('http://www.baidu.com/');
118     }
119 </script><script>
120     _sendCard = {
121         asyncJs : [],
122         asyncLoad : function(id){
```

层叠样式表(Cascading Style Sheets)是一种用来表现HTML（标准通用标记语言的一个应用）或XML（标准通用标记语言的一个子集）等文件样式的计算机语言。CSS不仅可以静态地修饰网页，还可以配合各种脚本语言动态地对网页各元素进行格式化。CSS 能够对网页中元素位置的排版进行像素级精确控制，支持几乎所有的字体字号样式，拥有对网页对象和模型样式编辑的能力。

浏览器开发者工具在爬虫中常用来进行简单的抓包分析、JS逆向调试，打开方式是在网页中按F12可调出开发者工具（以谷歌浏览器为例）。




Elements（元素面板）：该标签用来查看页面的HTML标签元素，能够查看源码，我们可以看到布局，可以看到用到的样式，还有用到的链接等等。




Console（控制台面板）：是一个web控制台，在开发期间，可以使用控制台面板记录诊断信息，或者使用它作为shell，在页面上与 JavaScript 交互。

Network（网络面板）：这个是抓包常用的工具，从发起网页页面请求 Request 后得到的各个请求资源信息（包括状态、资源类型、大小、所用时间等）都可以在这个页签看到。在数据抓取的时候，我们需要分析页面的请求，可以看到Headers（请求消息头） Preview（预览） Response（响应） Timing（请求时间） Cookie这些内容。



Network（网络面板）最上面还有一个工具栏，有一个红色的圆点和静止符号的按钮，那么这两个按钮，当为红色按钮的时候表示当前的请求不被清空（但是这里的请求是不跳转页面的请求，当跳转到新的页面，那么也会请求也会被清空），后面这个按钮就是清空请求的。



Python 内置了 requests 模块，该模块主要用来发送HTTP 请求获取响应的，其在python内置模块的基础上进行了高度封装，使得Requests能够轻松完成浏览器相关的任何操作。



方法	描述
<code>delete(url, args)</code>	发送 DELETE 请求到指定 url，请求服务器删除指定页面
<code>get(url, params, args)</code>	发送 GET 请求到指定 url，从服务器获取数据
<code>head(url, args)</code>	发送 HEAD 请求到指定 url，请求页面头部信息
<code>patch(url, data, args)</code>	发送 PATCH 请求到指定 url，向HTML提交局部修改请求，对应于HTTP的 PATCH
<code>post(url, data, json, args)</code>	发送 POST 请求到指定 url，向服务器提交数据
<code>put(url, data, args)</code>	发送 PUT 请求到指定 url，从客户端向服务器传送的数据取代指定的文档的内容
<code>request(method, url, args)</code>	向指定的 url 发送指定的请求方法，构造会话对象，上面的6个方法都可以用这个方法调用

Requests常用的方法的参数说明：

- url 请求 url。
- data 为要发送到指定 url 的字典、元组列表、字节或文件对象。
- json 为要发送到指定 url 的 JSON 对象。
- args 为其他参数，比如 cookies、headers、verify等。

示例2.4-1：通过requests模块中的方法抓取金蝶精一官网的网页信息，并输出。

示例2.4-1 代码

```
# 2-4 数数据采集任务 示例2.4-1
import requests #引入requests包
url = 'https://kone.kingdee.com/' #设置要爬取的网页的url
response = requests.get(url=url) #发送请求
page_text = response.text #获取网页响应的内容
print (page_text) #输出网页全部信息
```

运行结果

```
<!DOCTYPE html>
<html lang="zh">

<head>
  <meta name="google-site-verification" content="7M60mP8y2yhpEgJszluggqkrZh(RDGQs04NENMECY" />
  <meta name="baidu-site-verification" content="bvnFZ7laXq" />

  <meta charset="utf-8">
  <meta http-equiv="X-UA-Compatible" content="IE=edge">
  <meta name="viewport" content="width=device-width, initial-scale=1">
  <meta name="description" content="">
  <meta name="author" content="">
  <link rel="icon" href="/static/img/favicon.ico">
  <title>金蝶精一信息科技有限公司 社会参与教育, 教育服务社会</title>
  <link href="/static/bootstrap/css/bootstrap.min.css" rel="stylesheet">
```

response属性	功能
response.text	获取文本内容
response.content	获取二进制数据
response.status_code	获取状态码
response.headers	获取响应头
response.cookies	获取cookies信息
response.cookies.get_dict	以字典形式获取cookies信息
response.cookies.items	以列表形式获取cookies信息
response.url	获取请求的URL
response.history	获取跳转前的URL
response.json	获取json数据

示例2.4-2：通过requests模块中的方法抓取金蝶精一官网的网页信息，并输出不同的Response的响应信息。

示例2.4-2代码

```
# 2-4 数数据采集任务 示例2.4-2
import requests #引入requests包
url = 'https://kone.kingdee.com/' #设置要爬取的网页的url
response = requests.get(url=url) #发送请求
print("响应头: ")
print(response.headers)
print("\n")
print("状态码: ")
print(response.status_code)
print("\n")
print("获取cookies信息: ")
print(response.cookies)
print("\n")
print("以字典形式获取cookies信息: ")
print(response.cookies.get_dict())
print("\n")
print("URL: ")
print(response.url)
```

运行结果

```
响应头:
{'Date': 'Tue, 14 Feb 2023 01:13:46 GMT', 'Content-Type': 'text/html; charset=UTF-8', 'Transfer-Encoding': 'chunked', 'Connection': 'keep-alive', 'Set-Cookie': 'SESSION=Yjk4NW10ZjItNzllYS00YTZlLg5ZTWtNWQ4ZDY3OWIyN2U4; Path=/; Secure: HttpOnly', 'Content-Language': 'en-US', 'Content-Encoding': 'gzip', 'Server': 'elb'}
```

状态码:
200

获取cookies信息:
<RequestsCookieJar[<Cookie SESSION=Yjk4NW10ZjItNzllYS00YTZlLg5ZTWtNWQ4ZDY3OWIyN2U4 for kone.kingdee.com/>]>

以字典形式获取cookies信息:
<bound method RequestsCookieJar.get_dict of <RequestsCookieJar[Cookie(version=0, name='SESSION', value='Yjk4NW10ZjItNzllYS00YTZlLg5ZTWtNWQ4ZDY3OWIyN2U4', port=None, port_specified=False, domain='kone.kingdee.com', domain_specified=False, domain_initial_dot=False, path='/', path_specified=True, secure=True, expires=None, discard=True, comment=None, comment_url=None, rest={'HttpOnly': None}, rfc2109=False)]>>

URL:
https://kone.kingdee.com/

课堂练习1：通过request模块访问学校官网，输出官网全部信息。

Beautiful Soup 是一个可以从HTML或XML文件中提取数据的Python库。它能够通过你喜欢的转换器实现惯用的文档导航,查找,修改文档的方式。

引入BeautifulSoup包

```
#引入BeautifulSoup库  
from bs4 import BeautifulSoup
```

find_all () 方法是搜索当前tag的所有tag子节点,并判断是否符合过滤器的条件, 将所有满足条件的标签都返回, 以列表形式返回, 语法格式如下:


Find_all() 函数使用语法

```
find_all( name , attrs , recursive , string , **kwargs
```

参数名称	设置语法	参数使用说明
Name参数	<pre>soup.find_all("title") # [<title>The Dormouse's story</title>]</pre>	参数可以查找所有名字为 name 的tag,字符串对象会被自动忽略掉
attrs参数	<pre>soup.find_all("a", attrs={"class": "sister"}) # [< a c l a s s = " s i s t e r " href="http://example.com/elsie" id="link1">Elsie</pre>	将属性条件放在一个字典表中, 以键值对方式传递给attrs参数

示例2.4-3：抓取中车购供应商协同平台供应商页面第一页的供应商名称，并输出。

爬取数据的网页链接：https://www.crrcgo.cc/admin/crr_supplier.html



示例2.4-3代码

```
# 2-4 数数据采集任务 示例2.4-3
import requests #引入requests包
from bs4 import BeautifulSoup
url = 'https://www.crrcgo.cc/admin/crr_supplier.html'#设置要爬取
的网页的url
response = requests.get(url=url) #发送请求
page_text = response.text #获取网页响应的内容
soup=BeautifulSoup(page_text,'lxml') #将网页内容传入，实例化一个
BeautifulSoup对象

suppliers=soup.find_all("div",class_='detail_head')#找到要抓取的内
容
#print(suppliers)

for i in suppliers:
    p_name = i.select_one('p').text
    print(p_name)
```

运行结果

长春中车轨道车辆有限公司

成都大江化工有限公司


株洲名扬橡塑有限公司

中车北京二七车辆有限公司

锦州捷通铁路机械制造有限公司

BeautifulSoup — 示例3代码解析

以上代码示例中“`suppliers=soup.find_all("div",class_='detail_head')`”中`class = detail_head`，以及“`p_name = i.select_one('p').text`”中的`p`，需要在浏览器中打开开发者工具，在Elements面板中，找到供应商名称的位置，通过对html代码的解读得到。



Beautiful Soup中还有很多本次教材没有介绍到的常用方法，在学习过程中，可以查看官方帮组文档。

官方文档链接：<https://www.crummy.com/software/BeautifulSoup/bs4/doc.zh/#>

【说明】通过Beautiful Soup直接解析html的工作量相对比较大，因此在做爬虫程序的时候，可以分析网页加载数据的时候是否网页中有新的请求去获取数据的接口，如果有的话可以通过调用新的请求的方式去直接抓取接口返回的数据。

课堂练习2：参考示例3的网页链接，获取供应商的名称和供应商地址，按以下要求输出。

运行结果

公司名称	公司地址
长春中车轨道车辆有限公司	宽城区凯旋路2155号
成都大江化工有限公司	成都市成华区龙潭乡威灵村12组
株洲名扬橡塑有限公司	株洲市芦淞区董家段高科技工业园内
中车北京二七车辆有限公司	北京市丰台区张郭庄甲1号
锦州捷通铁路机械制造有限公司	锦州市太和区为民路90号

示例2.4-4：抓取中车购供应商协同平台供应商页面推荐榜中的合格供应商列表。

爬取数据的网页链接：https://www.crrcao.cc/crrc_Recommend.html



示例2.4-4代码

```
# 2-4 数数据采集任务 示例2.4-4
import requests #引入requests包
import json
url =
'https://purseller.crrcgo.cc/api/memberCompany/getTypeOneSupplierList?_t
1676367174821'#设置要爬取的合格供应商的数据获取接口
response = requests.get(url=url) #发送请求
page_text = response.text #获取网页响应的内容
#print(page_text)
data=json.loads(page_text) #将获取的网页响应的内容转化成json格式
#print(data)
companylist=data['obj'] #将获取json数据中，key为obj的数据存为元组
#print(companylist)
print("抓取到的合格供应商如下：")
for i in companylist:
    name=i['companyName'] #将获取元组中公司名称
    core=i['main_core'] #将获取元组中公司经营范围
    print("供应商公司名称："+name)
    print("经营范围："+core)
```

运行结果

抓取到的合格供应商如下：

供应商公司名称：南昌铁路装备制造制造有限公司

经营范围：机车车辆配件及材料的制造、维修、销售；防护栅栏制造、安装；铁路设备、器材制造、装、维修；铁路内燃、电力机车电机、电器修理及配件制造；门（桥）式起重机制造、安装、改造、维修；机电设备、钢材、建材批发；通用钢质集装箱的维修；道路普通货物运输（依法须经批准的项目


供应商公司名称：山西腾诺机电设备有限公司

经营范围：化工产品（不含危险品）、绝缘材料、金属材料（不含贵金属）、机电设备（不含小轿项目，经相关部门批准后方可开展经营活动）***


供应商公司名称：江苏迅达电磁线有限公司

经营范围：电磁线、电缆、电子元器件制造、销售；贵金属加工（不含冶炼）、销售；自营和代理各口的商品除外。（依法须经批准的项目，经相关部门批准后方可开展经营活动）



以上代码示例中 `response = requests.get(url=url)`，中的url信息，需要在浏览器中打开开发者工具，在Network面板中，找到合格供应商的数据来源，从以下信息可发现合格供应商数据是网页在加载的过程中通过一个新的request请求获取信息后再显示到页面中的。



点击headers, 可以看见页面加载过程中为了获取合格供应商的数据的接口请求信息, 该url就是可以用Request来访问的url。



在以上接口请求返回的Response和Preview中可以看见返回的数据是一个json对象，因此通过 `data=json.loads(page_text)` 将网页返回的文本信息转化成json对象。



课堂练习3：参考示例4的网页地址，获取活跃供应商的活跃度排名、公司名称和经营范围，按以下要求输出。

运行结果

抓取到的活跃供应商如下：

活跃度排名：1

供应商公司名称：中铁十一局集团有限公司

经营范围：可承接房屋建筑、公路、铁路、市政公用、港口与航道、水利水电、各类别工程的施工总承包、工程总承包和项目管理业务；电力工程施工总承包贰级、矿山工程施工总承包贰级、机电工程施工总承包贰级、桥梁工程专业承包壹级、隧道工程专业承包壹级、公路路面工程专业承包壹级、机场场道工程专业承包壹级、钢结构工程专业承包贰级；地质灾害防治工程施工；与地质环境治理和地质灾害防治有关的岩土工程施工；二级及以下爆破作业项目设计施工、安全评估、安全监理；工程设计铁道行业甲（II）级、建筑行业（建筑工程、人防工程）甲级、市政工程行业甲级、公路工程行业甲级；可承担建筑装饰工程设计、建筑幕墙工程设计、轻型钢结构工程设计、建筑智能化系统设计、照明工程设计和消防设施工程设计相应范围的甲级专项工程设计业务；可从事资质证书许可范围内相应的建设工程总承包业务及项目管理和相关的技术与管理服务；工程勘察专业类（岩土工程勘察）乙级；测绘资质甲级；承包境外工程及境内国际招标工程；上述境外工程所需的设备、材料出口；对外派遣实施上述境外工程所需的劳务人员；开展各种土木工程施工机械设备租赁；承担水泥制品和混凝土结构构件的生产制作；建筑物的内、外装修，装饰工程的施工；建筑材料、金属材料的销售；铁路运营与管理维护。（涉及许可经营项目，应取得相关部门许可后方可经营）

活跃度排名：2

供应商公司名称：北京市市政四建设工程有限责任公司

经营范围：施工总承包；工程设计、施工；机电设备安装、钢结构、预应力、防腐保温、压力管道安装；工程测绘、工程检测；技术咨询、技术培训；物业管理；设备物资采购、维修；设备组装；机械设备、施工材料租赁；货物进出口、技术进出口、代理进出口；销售建筑材料、五金交电、机械设备；城市园林绿化。（企业依法自主选择经营项目，开展经营活动；依法须经批准的项目，经相关部门批准后依批准的内容开展经营活动；不得从事本市产业政策禁止和限制类项目的经营活动。）

1 案例背景

2 知识准备


3 任务要求

4 任务解析

在东方财富网中针对金蝶国际抓取该公司的投资评级的全部数据存放到excel表中。

要抓取的数据的来源网页链接：

https://emweb.securities.eastmoney.com/PC_HKF10/pages/home/index.html?code=00268&type=web&color=w#/InvestmentRating



发布日期	机构名称	最新评级	上次评级	目标价格 (港元)	上次目标价 (港元)	目标价格变化
2023-02-14	188 International Capital Corporation Limited	买入	买入	23.56	23.51	↓ 下降
2023-01-06	国海证券股份有限公司	买入	买入	—	—	—
2022-12-01	海通国际证券集团有限公司	优于大市	优于大市	36.41	—	—
2022-11-22	西南证券股份有限公司	买入	买入	19.50	—	—
2022-11-14	Guotai Junan Securities (Hong Kong) Limited	Buy (买入)	—	30.2	—	—
2022-09-20	大同证券股份有限公司	买入	买入	17.70	—	—
2022-08-28	国元国际控股有限公司	买入	买入	15.7	—	—

1 案例背景

2 知识准备

3 任务要求

4 任务解析

任务编码主思路：


- 1、打开网页，同时打开网页的开发者工具。
- 2、在开发者工具下，查看页面元素和页面网络，分析后判断是通过接口获取数据还是要解析html元素来抓取数据
- 3、对爬取的数据做转换
- 4、调用pandas将数据写入excel表中

任务实现代码：

参考教材中的代码答案



在东方财富网中针对金蝶国际抓取该公司的关联权证的全部数据存放到excel表中。



感謝
ขอบคุณ
terima kasih
ありがとう
Thanks
谢谢